



UNIVERSIDADE DO MINHO

Escola de Engenharia  
Licenciatura em Engenharia Informática

## Introdução à Inteligência Artificial

Ano Letivo de 2025/2026

# Sistema de Extração de Informação e Chatbot - ChefBot

---

### AUTORES

<b>Tomás Henrique Alves Melo</b>	<b>PG60018</b>
<b>Rodrigo Miguel Granja Ferreira</b>	<b>PG60392</b>
<b>Luís Pinto da Cunha</b>	<b>PG60280</b>
<b>Nuno Filipe Leite Oliveira Araújo</b>	<b>PG61218</b>

IIA

## Resumo

O presente relatório descreve o desenvolvimento do **ChefBot**, um chatbot conversacional inteligente para assistência culinária, desenvolvido no âmbito da unidade curricular de Introdução à Inteligência Artificial. O sistema permite aos utilizadores descobrir receitas com base em diversos critérios (categoria, tempo disponível, dificuldade, restrições alimentares), pesquisar por ingredientes disponíveis ou por nome específico de receita, e acompanhar a preparação passo a passo.

O ChefBot foi implementado utilizando o framework **RASA Open Source** para processamento de linguagem natural (NLP) em português, integrado com um dataset de aproximadamente **1597 receitas portuguesas** extraídas da plataforma **PetitChef**. O sistema demonstra capacidades avançadas de compreensão de intenções, extração de entidades e gestão de diálogo contextual.

# Índice

<b>1. Introdução .....</b>	<b>1</b>
1.1. Objetivos .....	1
<b>2. Problema Escolhido e Motivação .....</b>	<b>1</b>
2.1. Contextualização .....	1
2.2. Motivação .....	2
2.3. Desafios .....	2
<b>3. Dataset e Preparação dos Dados .....</b>	<b>2</b>
3.1. Fonte de Dados .....	2
3.2. Processo de Extração .....	3
3.3. Processo de Limpeza & Identificação das Receitas .....	3
3.4. Estatísticas do Conjunto de Dados .....	4
3.5. Pré-processamento .....	5
<b>4. Tecnologias Escolhidas e Justificação .....</b>	<b>5</b>
4.1. Framework Principal: RASA Open Source .....	5
4.2. Alternativas Consideradas .....	6
4.3. Pipeline de NLU .....	6
4.4. Políticas de Diálogo .....	6
<b>5. Arquitetura do Sistema .....</b>	<b>7</b>
5.1. Domínio (domain.yml) .....	8
5.2. Regras (rules.yml) .....	8
5.3. Stories (stories.yml) .....	8
5.4. Ações Customizadas (actions.py) .....	9
5.5. Sistema de Persistência .....	9
5.5.1. favoritos.csv .....	9
5.5.2. recentes.csv .....	10
5.5.3. Sistema de Avaliação .....	10
5.6. Interface Web .....	10
5.6.1. Tecnologias .....	10
5.6.2. Funcionalidades .....	10
5.6.3. Comunicação com RASA .....	11
<b>6. Exemplos de Uso .....</b>	<b>11</b>
6.1. Descoberta Guiada .....	11
6.2. Pesquisa por Nome .....	12
6.3. Pesquisa por Ingredientes .....	12
6.4. Gestão de Favoritos .....	13
6.5. Receitas Recentes .....	13
6.6. Modo Passo-a-Passo .....	13
6.7. Pesquisa Direta por Categoria .....	14
6.8. Visualizar Receita Completa .....	14
<b>7. Reflexões Críticas .....</b>	<b>15</b>
7.1. Implementação .....	15
7.2. Limitações identificadas .....	15
7.3. Alternativa Considerada: RASA Pro com CALM .....	15
7.3.1. Comparação: RASA Clássico vs LLM .....	16
7.3.2. Desafios do NLP .....	16
<b>8. Conclusão .....</b>	<b>16</b>

8.1. Trabalho Futuro .....	16
<b>9. Referências .....</b>	<b>17</b>

# 1. Introdução

A culinária é uma atividade quotidiana que frequentemente envolve desafios de decisão: “O que posso cozinhar com os ingredientes que tenho?”, “Qual receita é adequada para o tempo disponível?”, “Que opções existem para restrições alimentares específicas?”. Estas questões representam um domínio ideal para a aplicação de técnicas de Processamento de Linguagem Natural (NLP) e sistemas de Question Answering (QA).

Este trabalho visa desenvolver um **agente de conhecimento conversacional** capaz de:

- Estabelecer diálogos naturais em português europeu
- Extrair informação relevante de uma base de conhecimento culinário
- Guiar utilizadores na descoberta e preparação de receitas
- Aprender preferências e manter histórico de utilização

## 1.1. Objetivos

Os objetivos específicos deste projeto incluem:

1. **Identificação do problema:** Definir um caso de uso relevante para extração de conhecimento
2. **Seleção de ferramentas:** Escolher e justificar tecnologias adequadas ao problema
3. **Implementação de pipeline:** Desenvolver um sistema de processamento e indexação de dados
4. **Desenvolvimento do chatbot:** Criar um sistema funcional de perguntas e respostas
5. **Avaliação:** Analisar o desempenho e limitações da solução
6. **Reflexão crítica:** Discutir desafios do NLP no contexto real

# 2. Problema Escolhido e Motivação

## 2.1. Contextualização

O domínio culinário apresenta características que o tornam particularmente interessante para sistemas de QA:

Característica	Descrição
Vocabulário estruturado	Ingredientes, técnicas e categorias bem definidas
Informação semiestruturada	Receitas com campos específicos (ingredientes, passos, tempo)
Interação natural	Utilizadores formulam perguntas de forma conversacional
Personalização	Necessidade de adaptar respostas a preferências individuais
Múltiplos critérios de pesquisa	Categoria, tempo, dificuldade, restrições, ingredientes

Tabela 1: Caracterização do domínio culinário

## 2.2. Motivação

A escolha deste domínio foi motivada por:

1. **Relevância prática:** A culinária é uma atividade universal com necessidade real de assistência
2. **Complexidade adequada:** O problema requer processamento de múltiplas entidades e contextos
3. **Disponibilidade de dados:** Existem fontes ricas de receitas em português
4. **Variedade de interações:** Permite explorar diferentes padrões de diálogo (descoberta guiada, pesquisa direta, acompanhamento passo a passo)

## 2.3. Desafios

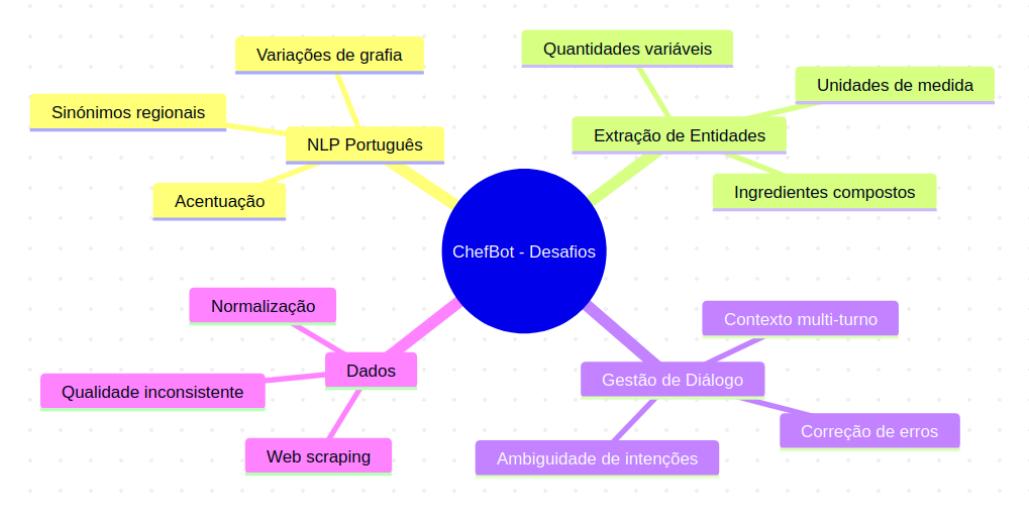


Figura 1: Desafios ChefBot

## 3. Dataset e Preparação dos Dados

### 3.1. Fonte de Dados

O dataset foi construído através de web scraping da plataforma PetitChef Portugal (<https://pt.petitchef.com/>), uma das maiores bases de dados de receitas em português. A escolha desta fonte deveu-se a:

- Receitas em português europeu
- Estrutura HTML consistente
- Grande variedade de categorias
- Informação nutricional incluída
- Ratings de utilizadores disponíveis

### 3.2. Processo de Extração

O script de extração (`extract_data.py`) utiliza as bibliotecas `requests` e `BeautifulSoup` para gerar um dataset (`petitchef_recipes.csv`) da seguinte forma:

```
# Categorias extraídas
CATEGORIAS = {
    "Entrada": "entrada",
    "Prato Principal": "prato-principal",
    "Sobremesa": "sobremesa",
}

# Critérios nutricionais identificados
CRITERIOS_POSSIVEIS = [
    "Sem glúten", "Vegan", "Vegetariano",
    "Sem lactose", "Sem açúcar", "Sem ovo",
]
```

#### Campos extraídos por receita

Campo	Descrição	Exemplo
titulo	Nome da receita	Creme de abóbora
categoria	Tipo de prato	Entrada
dificuldade	Nível de complexidade	Médio
tempo_total	Duração estimada	40 min
calorias	Valor nutricional	40 Kcal
rating	Avaliação média (0-5)	4.49
porcoes	Número de porções	8
ingredientes	Lista de ingredientes	300g abóbora   2 batatas...
passos	Instruções de preparação	Cortar...   Cozinhar...
criterios	Restrições alimentares	Sem glúten   Vegetariano
imagem	Imagen da receita	<a href="https://pt.petitchef.com/imgupl/recipe/creme-de-abobora-160575p240773.webp">https://pt.petitchef.com/imgupl/recipe/creme-de-abobora-160575p240773.webp</a>

Tabela 2: Campos extraídos por receita

### 3.3. Processo de Limpeza & Identificação das Receitas

Para além do script referido, foi criado também um programa para limpeza do dataset (`clean_csv.py`). Este lê o ficheiro de receitas gerado pelo script (`extract_data.py`) e gera um novo CSV limpo (`recipes_old.csv`).

Durante o processo, mantém a mesma estrutura de colunas, altera o separador de campos para ponto e vírgula e remove aspas simples e duplas dos campos de texto título e passos. Ainda, modifica o valor do campo ‘dificuldade’ de ‘Muito Fácil’ para ‘Fácil’. O resultado é um ficheiro CSV mais simples e consistente.

Por fim, foi criado o script (`add_id.py`) que lê o ficheiro (`recipes_old.csv`) e cria um novo ficheiro (`recipes.csv`), adicionando uma coluna id no início.

O cabeçalho original é mantido, mas passa a ter o campo id como primeira coluna. Em seguida, cada linha de dados recebe um identificador numérico incremental, começando em 1, garantindo que cada registo tem um identificador único.

O resultado é o ficheiro final (`recipes.csv`) com a mesma informação do ficheiro anterior, mas com uma chave identificadora explícita para cada linha.

### 3.4. Estatísticas do Conjunto de Dados

O dataset final contém **1597 receitas** distribuídas da seguinte forma:

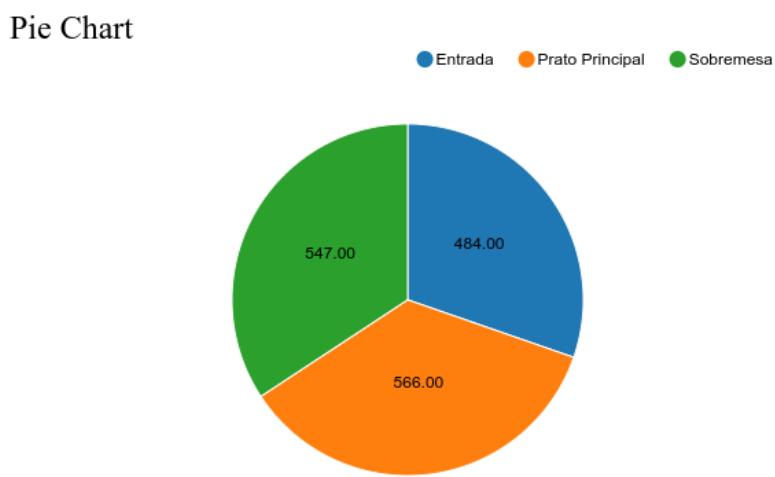


Figura 2: Distribuição por Categoria

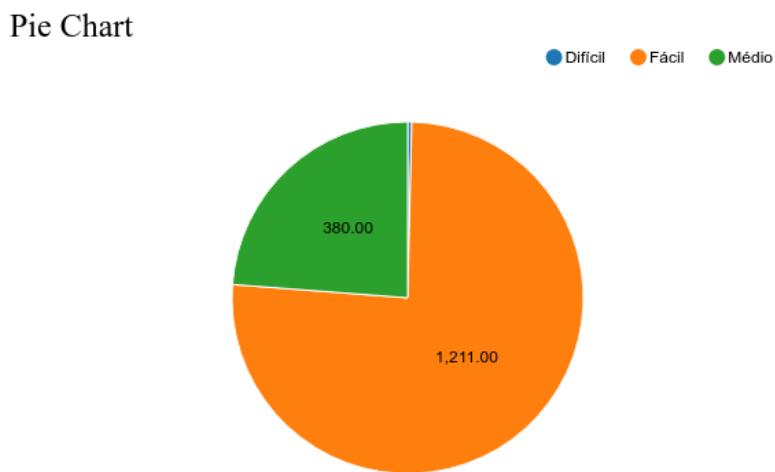


Figura 3: Distribuição por Dificuldade

#### Métricas de qualidade:

- Receitas com informação nutricional: 100%
- Receitas com rating: 100%
- Receitas com tempo total estimado: 100%
- Receitas com categoria: 100%

- Receitas com dificuldade: 100%
- Receitas com critérios alimentares: 89%
- Média de ingredientes por receita: 8-12
- Média de passos por receita: 6-10

A **qualidade dos dados** é garantida pelos critérios de extração de receitas que foram impostos no script de web scraping (`extract_data.py`).

### 3.5. Pré-processamento

O processamento dos dados incluiu:

1. **Tratamento de listas:** Separação por | de ingredientes e passos
2. **Filtragem de qualidade:** Exclusão de receitas incompletas (sem informação das calorias, rating, imagem e tempo estimado), com formatos não desejados (formato da lista de ingredientes divididos por categoria) ou com caracteres não desejados (títulos com '?' e ingredientes e passos com ',')
3. **Normalização:** Transformação da dificuldade do tipo 'Muito Fácil' para 'Fácil'

## 4. Tecnologias Escolhidas e Justificação

### 4.1. Framework Principal: RASA Open Source

A escolha para o desenvolvimento do chatbot recaiu sobre o RASA Open Source (versão 3.1). Esta decisão fundamenta-se, principalmente, na natureza de código aberto da plataforma, o que garante total soberania sobre os dados. Ao permitir o uso local e o funcionamento offline, o RASA assegura a privacidade das interações e elimina a dependência de serviços de terceiros na cloud, oferecendo um controlo que soluções proprietárias não permitem.

Do ponto de vista técnico, o RASA destaca-se pela sua arquitetura modular e extensível, permitindo uma customização profunda dos componentes de processamento de linguagem natural (NLP), o que é crucial para afinar o reconhecimento da língua portuguesa. A framework oferece suporte nativo robusto para a gestão de estado e preenchimento de slots, essencial para manter o contexto durante conversas longas. Adicionalmente, a possibilidade de escrever "Ações Customizadas" em Python confere flexibilidade para integrar lógica de negócio complexa. Por fim, o facto de ser uma solução gratuita, apoiada por uma comunidade ativa e documentação abrangente, valida a sua viabilidade económica e sustentabilidade a longo prazo.

## 4.2. Alternativas Consideradas

Antes de optar pelo RASA Open Source, foram avaliadas outras abordagens:

Abordagem	Vantagens	Razão da Exclusão
LLM Local (LLaMA/Mistral)	Respostas naturais, flexibilidade linguística	Latência elevada (2-4s), hardware insuficiente
TF-IDF + Python	Simples de implementar, rápido	Sem gestão de diálogo, sem contexto entre turnos
Híbrido (RASA + LLM)	Combina estrutura com flexibilidade	Complexidade excessiva, dependência de APIs

Tabela 3: Alternativas consideradas

A escolha do **RASA Open Source** ofereceu o melhor equilíbrio entre funcionalidade, velocidade e independência de serviços externos.

## 4.3. Pipeline de NLU

O pipeline de processamento de linguagem natural foi configurado com os seguintes componentes:

```
pipeline:
  - name: WhitespaceTokenizer      # Tokenização por espaços
  - name: RegexFeaturizer         # Features baseadas em regex
  - name: LexicalSyntacticFeaturizer # Features lexicais e sintáticas
  - name: CountVectorsFeaturizer   # Bag-of-words
  - name: CountVectorsFeaturizer   # Character n-grams (1-4)
    analyzer: char_wb
    min_ngram: 1
    max_ngram: 4
  - name: DIETClassifier          # Classificador dual (intent + entity)
    epochs: 100
    constrain_similarities: true
  - name: EntitySynonymMapper     # Mapeamento de sinónimos
  - name: FallbackClassifier       # Gestão de baixa confiança
    threshold: 0.7
```

### Justificação dos componentes:

1. **DIETClassifier**: Modelo *state-of-the-art* que combina classificação de intenções e extração de entidades numa única arquitetura transformer
2. **Character n-grams**: Essencial para português, capturando variações de escrita e tolerância a erros ortográficos
3. **FallbackClassifier**: Garante respostas *gracious* quando a confiança é baixa (threshold 0.7)

## 4.4. Políticas de Diálogo

```
policies:
  - name: MemoizationPolicy      # Memorização de histórias
    max_history: 5
  - name: RulePolicy              # Regras determinísticas
    core_fallback_threshold: 0.4
  - name: TEDPolicy                # Transformer para diálogo
    epochs: 100
  - name: UnexpectedIntentPolicy  # Detecção de intenções inesperadas
    max_history: 5
```

## 5. Arquitetura do Sistema

O ChefBot segue uma arquitetura modular e escalável, organizada em camadas distintas que separam responsabilidades e facilitam a manutenção e evolução do sistema. O sistema suporta uma **interface web moderna** desenvolvida em HTML + TailwindCSS.



Figura 4: Arquitetura do Projeto

## 5.1. Domínio (domain.yml)

O domínio define todos os elementos que o chatbot “conhece”. A tabela seguinte resume os componentes:

Componente	Quantidade	Exemplos
Intenções	36	greet, quero_cozinhar, escolher_categoria, proximo_passo...
Entidades	10	categoria, tempo, dificuldade, ingrediente_possuido...
Slots	14	categoria, tempo, receitas_encontradas, passo_atual...
Ações	28	action_buscar_receitas, action_proximo_passo...
Respostas	15	utter_greet, utter_perigar_categoria...

Tabela 4: Componentes do Domínio

Os **slots** são variáveis de memória que mantêm o contexto da conversa. Por exemplo, quando o utilizador escolhe “prato principal”, o slot categoria é preenchido e mantido até ao fim da pesquisa.

## 5.2. Regras (rules.yml)

Definem comportamentos que devem acontecer **sempre** da mesma forma:

Trigger	Ação
greet	utter_greet
goodbye	utter_goodbye
proximo_passo	action_proximo_passo
finalizar_receita	action_perigar_avaliacao
favoritar_sim	action_guardar_favoritos_csv
nlu_fallback	utter_default

Tabela 5: Algumas regras implementadas

## 5.3. Stories (stories.yml)

As *stories* definem sequências de interação para treinar o modelo de diálogo. O sistema suporta três fluxos principais:

1. **Descoberta guiada**: O utilizador é guiado por perguntas sequenciais (categoria → tempo → dificuldade → restrições → calorias) até obter sugestões de receitas.
2. **Pesquisa por ingredientes**: O utilizador indica os ingredientes disponíveis e o sistema calcula um score de correspondência para sugerir receitas compatíveis.
3. **Modo passo-a-passo**: Após selecionar uma receita, o utilizador pode verificar novamente o conjunto de ingredientes que a receita possui, navegar pelos passos de preparação, com opções de avançar, recuar ou abandonar a receita.

## 5.4. Ações Customizadas (actions.py)

As ações são funções Python que executam lógica complexa impossível de definir apenas com templates YAML.

Categoria	Ações	Função
Pesquisa	buscar_receitas	Filtrar por categoria, tempo, dificuldade e calorias
Pesquisa	buscar_por_ingredientes	Calcula score de match com ingredientes do utilizador
Pesquisa	buscar_por_nome	Pesquisa fuzzy por nome de receita
Modo Passo	proximo_passo	Avança no contador e mostra próxima instrução
Persistência	guardar_favoritos_csv	Escreve receita no ficheiro CSV de favoritos

Tabela 6: Principais ações customizadas

## 5.5. Sistema de Persistência

O ChefBot mantém dados do utilizador através de dois ficheiros CSV:

### 5.5.1. favoritos.csv

Guarda as receitas marcadas como favoritas pelo utilizador.

Campo	Descrição
data_favorito	Timestamp de quando foi guardado
id	Número identificador da receita
titulo	Nome da receita
categoria	Tipo de prato
dificuldade	Nível de complexidade
tempo_total	Duração estimada
tempo_minutos	Duração estimada em minutos
calorias	Valor nutricional
rating_dataset	Avaliação média (0-5)
criterios	Restrições alimentares
ingredientes	Lista de ingredientes
passos	Instruções de preparação

Tabela 7: Estrutura do favoritos.csv

### 5.5.2. recentes.csv

Regista as receitas finalizadas pelo utilizador, incluindo a **avaliação pessoal**.

Campo	Descrição
data_finalizacao	Timestamp de quando terminou a receita
id	Número identificador da receita
titulo	Nome da receita
categoria	Tipo de prato
dificuldade	Nível de complexidade
tempo_total	Duração estimada
tempo_minutos	Duração estimada em minutos
calorias	Valor nutricional
rating_dataset	Avaliação média (0-5)
criterios	Restrições alimentares
ingredientes	Lista de ingredientes
passos	Instruções de preparação
avaliacao_utilizador	Nota dada pelo utilizador (1-5 estrelas)

Tabela 8: Estrutura do recentes.csv

### 5.5.3. Sistema de Avaliação

Após finalizar uma receita no modo passo-a-passo, o utilizador é convidado a avaliar a experiência de 1 a 5 estrelas. Esta avaliação é guardada no recentes.csv.

O sistema também identifica:

- **Receita mais realizada:** a que aparece mais vezes no histórico
- **Última receita:** a mais recentemente finalizada

## 5.6. Interface Web

### 5.6.1. Tecnologias

- **HTML5** — estrutura da página
- **TailwindCSS** — estilização moderna via CDN
- **JavaScript** — comunicação com RASA (fetch API)
- **localStorage** — persistência do histórico

### 5.6.2. Funcionalidades

- **Chat em tempo real** com o servidor RASA
- **Histórico de conversas** guardado localmente (até 50 conversas)
- **Botões interativos** renderizados automaticamente
- **Quick Actions:** atalhos para “Quero cozinhar algo”, “Favoritos”, “Recentes”

- **Sidebar retrátil** para gestão de conversas anteriores
- **Design responsivo** adaptável a desktop e mobile

#### 5.6.3. Comunicação com RASA

A interface comunica com o endpoint `http://localhost:5005/webhooks/rest/webhook` enviando mensagens em JSON e recebendo respostas com texto e botões.

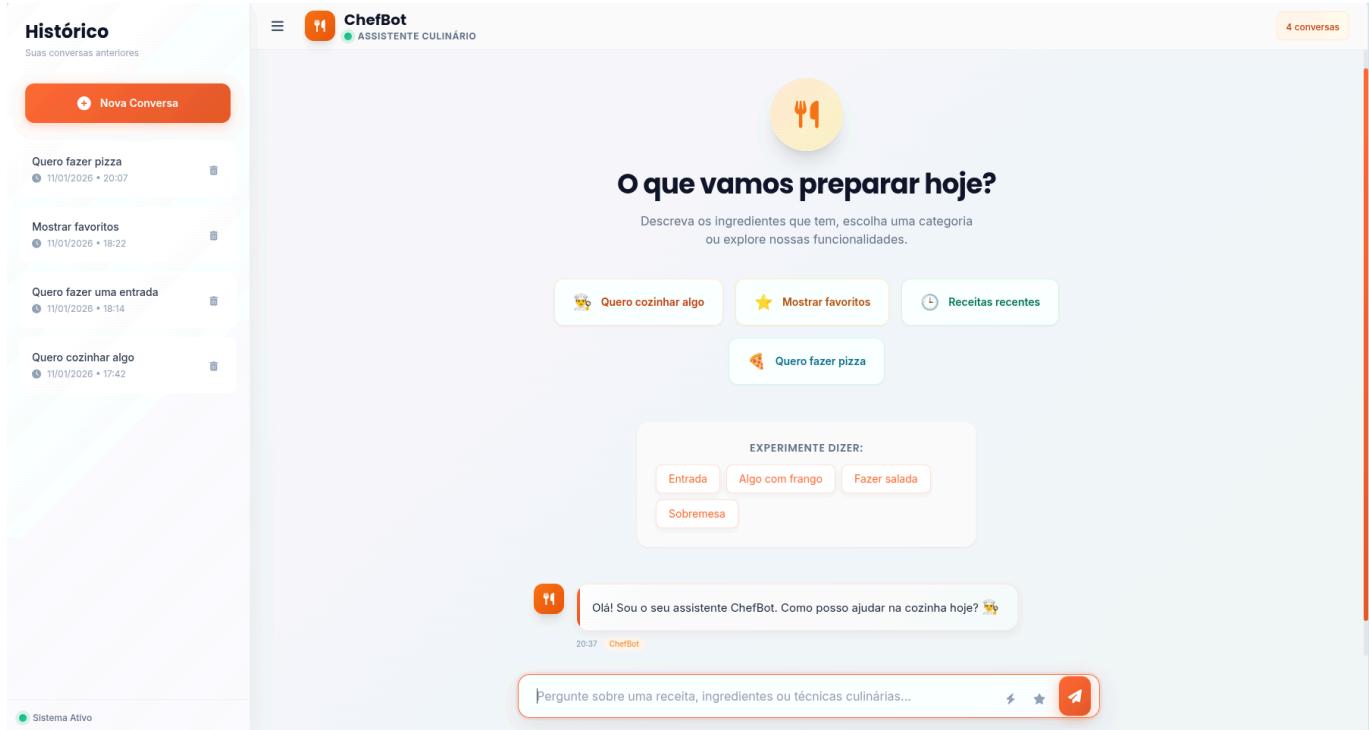


Figura 5: Interface Web do ChefBot

## 6. Exemplos de Uso

### 6.1. Descoberta Guiada

**👤 Utilizador:** Quero cozinhar algo  
**🤖 ChefBot:** Ótimo! Que tipo de prato queres fazer?  
 [🥗 Entrada] [🔥 Prato principal] [🍰 Sobremesa]

**👤 Utilizador:** Prato principal  
**🤖 ChefBot:** Quanto tempo tens disponível?  
 [⚡ Até 30min] [⌚ 30-60min] [🕒 Mais de 1h] [👷 Tanto faz]

**👤 Utilizador:** Tanto faz  
**🤖 ChefBot:** Qual o nível de dificuldade que procuras?  
 [😊 Fácil] [🤔 Médio] [❗ Difícil] [🎯 Qualquer]

 **Utilizador:** Qualquer

 **ChefBot:** Tens alguma restrição alimentar?

- [🌿 Vegetariano] [\_VEGETARIANO] [VEGAN] [SEM GLUTEN] [SEM LACTOSE]
- [🚫 Sem açúcar] [SEM ACUCAR] [SEM OVO] [NENHUMA]

 **Utilizador:** Sem Açúcar

 **ChefBot:** Queres uma opção mais leve ou não te importas com as calorias?

- [🥗 Leve (até 300 cal)] [MODERADO] [REFORÇADO (600-900)]
- [💪 Hipercalórico (+900)] [SEM RESTRIÇÃO]

 **Utilizador:** Leve

 **ChefBot:** A procurar as melhores receitas para ti... 

 **ChefBot:** Encontrei 5 receitas! 

1. 😋 **Rolos de berinjela à parmegiana** — 🕒 1h | 🔥 223 Kcal
2. 😋 **Quiche de tomate e queijo curado** — 🕒 40 min | 🔥 235 Kcal
3. 😋 **Tacos chamuças de carne picada** — 🕒 35 min | 🔥 94 Kcal
4. 😋 **Hambúrguer vegetariano de abobrinha** — 🕒 45 min | 🔥 278 Kcal
5. 😋 **Flan de legumes** — 🕒 40 min | 🔥 218 Kcal

## 6.2. Pesquisa por Nome

 **Utilizador:** Quero fazer pizza

 **ChefBot:** Encontrei 8 receitas! 

1. 😋 **Pizza kitkat** — 🕒 42 min | 🔥 167 Kcal
2. 😋 **Pizza em trouxas** — 🕒 30 min | 🔥 469 Kcal
3. 😋 **Pizza de melancia** — 🕒 20 min | 🔥 41 Kcal
4. 😋 **Pizza doce nutella e banana** — 🕒 25 min | 🔥 132 Kcal
5. 😋 **Waffle pizza** — 🕒 34 min | 🔥 2608 Kcal

## 6.3. Pesquisa por Ingredientes

 **Utilizador:** Tenho batata e ovos, o que posso fazer?

 **ChefBot:** Encontrei 5 receitas com esses ingredientes! 

1. 😋 **Tortilha espanhola** — 🕒 35 min | 🔥 245 Kcal
2. 😋 **Ninho de páscoa** — 🕒 42 min | 🔥 100 Kcal

## 6.4. Gestão de Favoritos

👤 Utilizador: Mostra os meus favoritos

🤖 ChefBot: Tens 5 receitas guardadas nos favoritos:

1. 😊 Sopa fria de ervilhas — 🕒 20 min | 🔥 965 Kcal
2. 😊 Waffles super proteicos com whey — 🕒 8 min | 🔥 125 Kcal
3. 😊 Salada de pepino com molho de iogurte — 🕒 5 min | 🔥 52 Kcal
4. 😊 Salada de damasco assado e burrata — 🕒 20 min | 🔥 976 Kcal
5. 😊 Croquete de peixe com limão — 🕒 20 min | 🔥 92 Kcal

## 6.5. Receitas Recentes

👤 Utilizador: Mostra as receitas recentes

🤖 ChefBot: Tens 6 receitas feitas recentemente:

⭐ Mais feita: Tigela de skyr com frutas vermelhas

📅 Última: Sopa fria de ervilhas

## 6.6. Modo Passo-a-Passo

👤 Utilizador: Começar modo passo-a-passo

🤖 ChefBot: Tens todos os ingredientes?

[ Sim, vamos lá] [ Mostrar ingredientes primeiro]

👤 Utilizador: Sim, vamos lá

🤖 ChefBot: PASSO 1 de 5

Pré-aqueça o forno a 180°C.

[← Próximo passo] [● Abandonar receita]

👤 Utilizador: Próximo

🤖 ChefBot: PASSO 2 de 5

Abra a massa folhada e espalhe o Nutella.

[← Próximo passo] [← Regressar passo] [● Abandonar receita]

... continua até ao último passo ...

👤 Utilizador: Finalizar

🤖 ChefBot: 🎉 Parabéns! Terminaste a receita! Como correu?

[1 estrela ★] [2 estrelas ★★] [3 estrelas ★★★]

[4 estrelas ★★★★] [5 estrelas ★★★★★]

👤 Utilizador: 5 estrelas

🤖 ChefBot: Guardar nos favoritos?

[ Sim, guardar] [ Não guardar]

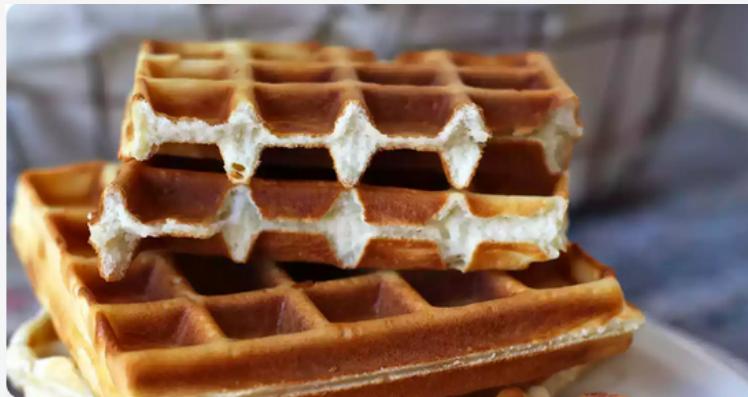
## 6.7. Pesquisa Direta por Categoria

- 👤 Utilizador: Quero fazer um prato principal  
🤖 ChefBot: Encontrei 3 receitas de prato principal! 🔎  
1. 😊 Arroz de pato — 🕒 1h 30 min | 🔥 450 Kcal  
2. 😮 Bacalhau à Brás — 🕒 45 min | 🔥 380 Kcal  
3. 😊 Frango assado — 🕒 1h | 🔥 320 Kcal

## 6.8. Visualizar Receita Completa

👤 Utilizador: Ver receita 2

🤖 ChefBot:



### 🔍 WAFFLES SUPER PROTEICOS COM WHEY

🕒 8 min | 📈 Fácil | 🔥 125 Kcal

⭐ Rating: 5.0/5

👤 Porções: 6

✓ Info: Vegetariano, Sem açúcar

#### 🛒 Ingredientes:

- 100g farinha de trigo
- 2 ovos
- 1 col. chá de fermento
- 180ml de leite
- 35g de whey baunilha

#### 👩‍🍳 Passos:

1. Coloque todos os ingredientes no mixer.
2. Misture até ficar homogêneo.
3. Unte a forma de waffle.
4. Despeje a massa na forma de waffle. Cozinhe os waffles por cerca de 3 minutos (dependendo da potência da sua máquina de waffles).
5. Retire os waffles quando estiverem dourados.
6. Está pronto. Bom apetite!

## 7. Reflexões Críticas

### 7.1. Implementação

- Fluxo de descoberta guiada intuitivo com botões
- Modo passo-a-passo prático para cozinhar
- Pesquisa por ingredientes com sistema de scoring
- Pesquisa por nome de receitas

### 7.2. Limitações identificadas

- **Vocabulário limitado:** Depende dos exemplos de treino
- **Pesquisa aproximada:** “tomate” pode não encontrar “tomates cherry”
- **Sem compreensão semântica:** Não entende equivalências (ex: “presunto” ≠ “fiambre”)

### 7.3. Alternativa Considerada: RASA Pro com CALM

Durante a fase inicial de arquitetura do sistema, foi explorada a utilização do **RASA Pro** com a tecnologia **CALM (Conversational AI with Language Models)**. Esta abordagem representa uma mudança de paradigma, delegando a gestão do fluxo de conversação e a compreensão do contexto para Grandes Modelos de Linguagem (LLMs), em vez de depender estritamente de classificadores de intenções e histórias pré-definidas.

Para o motor de raciocínio (**reasoning engine**), foi realizada uma integração com o modelo **Google Gemini**. No entanto, esta implementação enfrentou obstáculos significativos:

1. **Limitações de API:** A dependência da API da Google resultou em bloqueios frequentes devido a **rate limits** (quotas de utilização) e instabilidade decorrente de atualizações na plataforma, o que comprometeu o fluxo de desenvolvimento contínuo.
2. **Latência em Modelos Locais:** Como tentativa de mitigação para reduzir a dependência de APIs externas, procurou-se substituir o Gemini por um **LLM local**. Contudo, esta solução revelou-se inviável em termos de **performance** no hardware disponível. O tempo de inferência elevado resultava numa latência inaceitável para uma interação em tempo real, degradando a experiência do utilizador.

Face a estes desafios técnicos, a imprevisibilidade de serviços externos e o custo computacional proibitivo de soluções locais, optou-se por regressar à arquitetura clássica do **RASA Open Source**. Esta decisão garantiu um sistema mais robusto, rápido e previsível, onde o controlo do diálogo é assegurado por políticas explícitas e um pipeline de NLU otimizado, sem a latência associada à geração de texto por LLMs.

### 7.3.1. Comparação: RASA Clássico vs LLM

Aspetto	RASA Open Source	RASA Pro + LLM
Latência	50-100ms	2s-4s
Offline	Sim	Não (API)
Custo	Gratuito	Pago (tokens)
Controlo	Total (regras explícitas)	Limitado (LLM decide)
Previsibilidade	Alta	Baixa (respostas variáveis)
Flexibilidade	Média (treino manual)	Alta (compreende variações)

Tabela 9: Comparação entre abordagens

A solução atual privilegia **robustez, velocidade e previsibilidade** sobre a flexibilidade linguística que um LLM ofereceria. Para um domínio estruturado como receitas, onde as interações são relativamente prevíveis, esta troca revelou-se vantajosa.

### 7.3.2. Desafios do NLP

- Variabilidade linguística do português
- Ambiguidade contextual (“leve” pode ser calorias ou dificuldade)
- Dados do web scraping com inconsistências que necessitaram de maior atenção

## 8. Conclusão

Este trabalho demonstrou a viabilidade de desenvolver um assistente culinário conversacional utilizando o RASA Open Source. O ChefBot consegue:

- Estabelecer diálogos naturais em português
- Guiar utilizadores na descoberta de receitas através de múltiplos critérios
- Pesquisar receitas por ingredientes ou nome
- Acompanhar a preparação passo-a-passo
- Manter histórico de favoritos, receitas recentemente e conversas

## 8.1. Trabalho Futuro

1. **Integração com LLM:** Usar modelos locais (LLaMA/Mistral) para respostas mais naturais
2. **Sistema de recomendação:** Sugerir receitas com base no histórico do utilizador
3. **Substituições inteligentes:** Sugerir alternativas para ingredientes em falta
4. **Planeamento semanal:** Geração automática de menus

## 9. Referências

1. RASA Open Source Documentation. (2024). *Building Contextual AI Assistants*. <https://rasa.com/docs/>
2. PetitChef Portugal. (2024). *Receitas de Culinária*. <https://pt.petitchef.com/>
3. Bunk, T., Varber, D., & Morise, H. (2020). *DIET: Lightweight Language Understanding for Dialogue Systems*. arXiv preprint.
4. Como Utilizar Beautiful Soup para Web Scraping. (2024). Asimov Academy. <https://hub.asimov.academy/tutorial/como-utilizar-beautiful-soup-para-web-scraping/>